

第二节课习题

2. 熟悉 Eigen 矩阵运算

2.1 在什么条件下, x 有解且唯一

在 A 为方阵的前提下, 当 A 满秩的时候, $Ax = b$ 中 x 有唯一解

2.2 高斯消元法的原理是什么?

利用有限次初等变换将增广矩阵 $[A|b]$ 转化为行阶梯阵(上三角矩阵), 然后通过回代过程依次解出 $x_n, x_{n-1}, \dots, x_2, x_1$.

2.3 QR 分解的原理是什么?

QR 分解将矩阵分解为 Q^*R 的乘积形式, 其中 Q 为正交矩阵($Q^T Q = I$), R 为上三角矩阵。QR 分解经常用来解线性最小二乘法问题。QR 分解也是特定特征值算法即 QR 算法的基础。QR 分解的实际计算有很多方法, 例如 Givens 旋转、Householder 变换, 以及 Gram-Schmidt 正交化等等。

2.4 Cholesky 分解的原理是什么?

Cholesky 分解是将一个对称正定矩阵分解为 L^*L^T 的乘积形式, 其中 L 为下三角矩阵。由于 Cholesky 分解的前提是对称正定矩阵, 所以矩阵的所有特征值都是大于零的, 导致分解的下三角矩阵的对角线元素也是大于零的。求解 $Ax = b$ 时, 可利用 Cholesky 分解, 将等式转化为 $LL^T x = b$, 然后利用前向迭代求解 $Ld = b$ 中的 d , 再利用后向迭代解出 $L^T x = d$ 中 x 。

2.5 编程实现 A 为 100×100 随机矩阵时, 用 QR 和 Cholesky 分解求 x 的程序, 可以参考本次课程用到的 useEigen 例程。

程序源文件 qr_cholesky_test.cpp 和可执行文件 qr_cholesky_test 位于文件夹 QR_Cholesky_Test 内。

3. 矩阵论基础

3.1 什么是正定矩阵和半正定矩阵?

1) 设 A 是 n 阶方阵, 如果对任何非零向量 X , 都有 $X^T A X > 0$, 其中 X^T 表示 X 的转置, 则 A 为正定矩阵。

对于复数的情况, 如果对任何非零的复向量 X , 都有 $X^H A X > 0$, 其中 X^H 表示 X 的共轭转置, 则 A 为正定矩阵。

2) 设 A 是 n 阶方阵, 如果对任何非零向量 X , 都有 $X^T A X \geq 0$, 其中 X^T 表示 X 的转置, 则 A 为半正定矩阵。

对于复数的情况, 如果对任何非零的复向量 X , 都有 $X^H A X \geq 0$, 其中 X^H 表示 X 的共轭转置, 则 A 为半正定矩阵。

性质 1: 若 A 为正定矩阵, 则 A 的特征值均为正。若 A 为半正定矩阵, 则 A 的特征值均为非负。

性质 2: 若矩阵 A 满足 $A = B^T B$, 则该对称矩阵 A 一定至少是一个半正定矩阵, 因为对于任何非零向量 X , 都有 $X^T A X = X^T B^T B X = \|BX\|^2 \geq 0$; 当 $Bx = 0$ 不存在非零解时, 即 B 列满秩时, 则 A 为正定矩阵。

3.2 对于方阵 A , 它的特征值是什么? 特征向量是什么? 特征值一定是实数吗? 如何计算一个矩阵的特征值?

1) 设 A 是 n 阶方阵, 如果存在数 λ 和非零 n 维列向量 x , 使得 $Ax = \lambda x$ 成立, 则称 λ 是 A 的一个特征值, 非零 n 维列向量 x 称为矩阵 A 对应于特征值 λ 的特征向量。

2) 特征值不一定是实数, 也可能是复数(包括纯虚数)。

3) 计算矩阵特征值的步骤:

1. 计算满足行列式 $\det(A - \lambda I) = 0$ 的所有 λ 值即为 A 的所有特征值。
2. 对于每一个特征值 λ 求出对应的非零特征向量 x , 满足 $(A - \lambda I)x = 0$

3.3 什么是矩阵的相似性? 相似性反映了什么几何意义?

1) 相似矩阵指存在相似关系的矩阵。两个 $n \times n$ 矩阵 A 与 B 为相似矩阵当且仅当存在一个 $n \times n$ 的可逆矩阵 P , 使得:

$$P^{-1}AP = B$$

P 被称为矩阵 A 与 B 之间的相似变换矩阵。判断两个矩阵是否相似的必要而非充分条件为:

1. 判断特征值是否相等; 2. 判断行列式是否相等; 3. 判断迹是否相等; 4. 判断秩是否相等。

2) 相似性的几何意义: 相似的矩阵是同一个线性变换在不同基/坐标系下的的不同描述。线性变换若粗略看成一个刚体的特定运动。刚体的特定运动是同一个, 但坐标系改变的话这个运动的描述函数就会不一样, 如果这个函数可用矩阵等价替代的话, 一个坐标系就对应着一个矩阵, 因此这些矩阵就不同, 但这些矩阵必有关系, 这个关系就是相似。

直观一点描述:

若 A 是线性变换 L 在基底 $\{a_1, \dots, a_n\}$ 下的表示矩阵

B 是线性变换 L 在基底 $\{b_1, \dots, b_n\}$ 下的表示矩阵

那么相似变换矩阵 P 就是从 $\{a_1, \dots, a_n\}$ 到 $\{b_1, \dots, b_n\}$ 的线性变换在 $\{a_1, \dots, a_n\}$ 坐标系下的表示矩阵。

3.4 矩阵一定能对角化吗? 什么样的矩阵能保证对角化? 不能对角化的矩阵能够形成什么样的形式(Jordan 标准形)?

1) 矩阵不一定能对角化。若 S 为特征向量矩阵: $S = [x_1, x_2, \dots, x_n]$, 其中 x_1, x_2, \dots, x_n 为矩阵 A 的 n 个特征向量, 矩阵对角化公式为 $S^{-1}AS = \Lambda$, 其中 Λ 为对角化矩阵, 对角元素为 n 个特征值:

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

由此可见矩阵 A 若要对角化成功, 那么特征向量矩阵 S 必须可逆, 即 S 必须满秩, 也就是说 A 的 n 个特征向量必须线性无关。

注意: 若矩阵 A 的特征值重复, 并不代表矩阵 A 的特征向量重复, 并代表其不能被对角化, 例如单位矩阵 I 拥有重复的特征值, 但是每个特征向量都线性无关, I 可以对角化, I 的对角化矩阵就是自己。

2) 如果矩阵 A 的各个特征向量线性无关, 则矩阵 A 可以被对角化。

矩阵 A 的各个特征向量线性无关的一种特殊情况是实对称矩阵:

实对称矩阵能够保证对角化, 因为实对称矩阵的不同特征值对应的特征向量是两两垂直(正交)的, 保证了各个特征向量的线性无关性。

3) 所有的 n 阶方阵都可以化为“若尔当 Jordan 标准型”, 其中可对角化的矩阵可以化为若尔当标准型的特例——对角标准型, 而不可对角化的矩阵可以化为一般性的若尔当标准型, 即若干个主对角线为特征值(其中一些特征值可以相等), 下方(或上方)次对角线全为 1, 其余全为 0 的若尔当块组成的矩阵。

3.5 奇异值分解 (SVD)是什么意思?

对于任意一个 $m \times n$ 阶的矩阵 A 存在一个分解, 使得

$$A = U\Sigma V^T$$

其中:

U 是 $m \times m$ 阶的正交矩阵, U 的列向量由 AA^T 的特征向量构成。

Σ 为 $m \times n$ 阶半正定对角矩阵(也就是说对角元素可能为零), 对角线上的元素称为奇异值, 其中非零奇异值是 AA^T 或 A^TA 的非零特征值的平方根。

V 为 $n \times n$ 阶的正交矩阵, V 的列向量由 A^TA 的特征向量构成。

这样的分解就称为奇异值分解。

3.6 矩阵的伪逆是什么意思 (Pseudo inverse)? 莫尔-彭多斯逆是如何定义的? 怎么计算一个矩阵的伪逆?

1) 众所周知只有非奇异的方阵才有逆矩阵, 非方阵或奇异方阵没有逆矩阵。后来将非奇异方阵的逆矩阵推广到非方阵以及奇异的方阵, 将得到所谓的广义逆矩阵, 也称为伪逆, 它具有部分逆矩阵的特性, 但不一定具有逆矩阵的所有特性。对于任意一个矩阵 A , A 的伪逆 A^+ 必然存在, 满足 $AA^+A = A$

2) 根据莫尔-彭多斯条件可以定义不同的广义逆阵, 对于任意 $m \times n$ 阶矩阵 A , 莫尔-彭多斯逆 A^+ 需同时满足以下四个条件:

1. $AA^+A = A$
2. $A^+AA^+ = A^+$
3. $(AA^+)^H = AA^+$
4. $(A^+A)^H = A^+A$

3)

如果 A 是一个 $n \times n$ 阶方阵, 并且 A 满秩($\text{rank}(A) = n$), 那么 A 的伪逆矩阵就是 A 的逆 A^{-1}

如果 A 是一个 $m \times n$ 阶矩阵, 且 $m > n$, 并且 A 列满秩($\text{rank}(A) = n$), 那么 A 可以定义左伪逆矩阵为 $A^+ = (A^HA)^{-1}A^H$

如果 A 是一个 $m \times n$ 阶矩阵, 且 $m < n$, 并且 A 行满秩($\text{rank}(A) = m$), 那么 A 可以定义右伪逆矩阵为 $A^+ = A^H(AA^H)^{-1}$

如果 $m \times n$ 阶矩阵 A 是任意一个秩亏损的矩阵($\text{rank}(A) < \min(m, n)$), 那么只能通过 SVD 分解公式 $A = U\Sigma V^T$ 来求解 A 的伪逆 A^+ :

$$A^+ = V\Sigma^+U^T$$

其中 Σ^+ 为 $n \times m$ 阶, 是将 Σ 对角线上的非零元素取倒数后再转置得到的。

3.7 对于超定方程: $Ax = b$ 且 A 不可逆时, 我们通常计算最小二乘解: $x = \arg \min_x \|Ax - b\|$ 。线性方程的最小二乘解在代数意义上是可以解析地写出来地。请回答以下问题:

(a) 在 $b \neq 0$ 时, x 的解是什么形式? 事实上, 我们可以对 A 求奇异值或对于 A^TA 求特征值。请阐述两者之间的关系。

由于 $Ax = b$ 为超定方程, 故 A 为 $m \times n$ 阶非方阵, 且 $m > n$, 故无法通过 $x = A^{-1}b$ 求得解。由于解的是超定方程, 若 A 列满秩的情况下, 可以使用左伪逆矩阵 $A^+ = (A^TA)^{-1}A^T$ 。这样就得到了最小二乘解 $x = A^+b = (A^TA)^{-1}A^Tb$

我们也可以通过求解矩阵 A 的奇异值来求解该超定方程:

先做奇异值分解 $A = U\Sigma V^T$, 其中的 A 的非零奇异值就是 AA^T 或 A^TA 的非零特征值的平方根。然后再求伪逆 $A^+ = V\Sigma^+U^T$, 最后可以得到解为 $x = A^+b$

(b) 当 $b = 0$ 时, 我们希望求 x 的非零解。请说明如何求解 x 。

由于 $Ax = 0$ 为超定方程, 方程数量多于未知数, 故不存在非零的精确解, 我们只能找到一组非零的近似解 x^+ 使得

$$x^+ = \arg \min \|Ax\|^2$$

我们可以限制 $\|x\|^2 = 1$, 因为如果 x 是 $Ax = 0$ 的一个非零解, 那么 kx 也是一个非零解 (k 为任意标量)。所以我们得到一个带约束的优化问题:

$$x^+ = \arg \min \|Ax\|^2, \text{ subject to } \|x\|^2 = 1$$

利用拉格朗日法将其转化成无约束优化问题:

$$L(x, \lambda) = \|Ax\|^2 + \lambda(1 - \|x\|^2) = x^T A^T A x + \lambda(1 - x^T x)$$

为求极值对其进行求导:

$$\frac{\partial L(x, \lambda)}{\partial x} = 2A^T A x - 2\lambda x = 0$$

$$\frac{\partial L(x, \lambda)}{\partial \lambda} = 1 - x^T x = 0$$

由此我们得到关于最优解的等式:

$$A^T A x = \lambda x$$

我们发现 λ 和 x 分别为 $A^T A$ 的特征值和特征向量, 但是 $A^T A$ 的特征值和特征向量有很多。我们将其带入待优化式子, 得到

$$\|Ax\|^2 = x^T A^T A x = x^T \lambda x = \lambda x^T x = \lambda$$

由此可以发现 $A^T A$ 的最小特征值 λ_{\min} 就是 $\|Ax\|^2$ 的最小值, 该特征值 λ_{\min} 对应的特征向量 x 就是 $Ax = 0$ 的近似解。

(c) 请谈谈你对上述解法在几何意义上的理解。该问题为开放问题。

对于求伪逆的方法解 $Ax = b$ 的几何理解:

由于我们无法找到解 x , 使得 b 直接落在 Ax 的向量空间上, 故只能求 b 在 Ax 空间上的投影, 根据投影的定义有 $b - Ax$ 垂直于空间 A , 故 $A^T(b - Ax) = 0$, 即为 $A^T A x = A^T b$, 这样就得到了最小二乘解 $x = (A^T A)^{-1} A^T b$, 其中 A 的伪逆为 $A^+ = (A^T A)^{-1} A^T$ 。由此可见对于求解超定方程, 一般适用左逆矩阵。

对于使用奇异值分解的方法解 $Ax = b$ 的几何理解:

等式 $Ax = b$ 结合奇异值分解 $A = U \Sigma V^T$ 从几何意义上而言, 就是利用 $m \times n$ 阶矩阵 A 将向量 x 从 V 这组正交基向量空间旋转到 U 这组正交向量基空间, 并对每个方向以奇异值为缩放因子进行缩放。为了解 $Ax = b$ 这个方程得到 x , 我们可以将这个进行反向推导, 伪逆 $A^+ = V \Sigma^+ U^T$ 就是将 b 从 U 这组正交基向量空间旋转到 V 这组正交向量基空间, 并对每个方向以奇异值的倒数为缩放因子进行反向缩放。这样就得到解 $x = A^+ b = V \Sigma^+ U^T b$

4. 几何运算练习

4.1 说明一个激光传感器下看的点应该如何计算它的世界坐标。

激光传感器下看到的点 v_L 可经过三次坐标变换计算得到世界坐标, 分别为

从激光传感器系到 Body 系:

$$\text{通过平移加旋转 } v_B = R_{BL} v_L + t_{BL} \quad \text{或者} \quad \text{通过齐次坐标的欧式坐标变换 } \begin{bmatrix} v_B \\ 1 \end{bmatrix} = T_{BL} \begin{bmatrix} v_L \\ 1 \end{bmatrix}$$

再从 Body 系到 R 系:

$$\text{通过平移加旋转 } v_R = R_{RB} v_B + t_{RB} \quad \text{或者} \quad \text{通过齐次坐标的欧式坐标变换 } \begin{bmatrix} v_R \\ 1 \end{bmatrix} = T_{RB} \begin{bmatrix} v_B \\ 1 \end{bmatrix}$$

最后再从 R 系到世界系 W:

$$\text{通过平移加旋转 } v_W = R_{WR} v_R + t_{WR} \quad \text{或者} \quad \text{通过齐次坐标的欧式坐标变换 } \begin{bmatrix} v_W \\ 1 \end{bmatrix} = T_{WR} \begin{bmatrix} v_R \\ 1 \end{bmatrix}$$

4.2 计算这个点在激光系下的坐标和世界系下的坐标

现在只知道该点在相机传感器系下的坐标为 $v_C = [0.3, 0.2, 1.2]^T$

(a) 求该点在激光系下的坐标, 可以按照相机系 C >>> Body 系 B >>> 激光系 L 进行转化

(b) 求该点在世界系下的坐标, 可以按照相机系 C >>> Body 系 B >>> 机器人系 R >>> 世界系 W 进行转化

程序源代码见文件夹 Geometry_Exercise, 程序先使用四元数(quaternion)进行坐标转换, 再使用欧式变换(Isometry)对求得的结果进行验证, 两种方法结果一致, 见下图。

```
jindong@jindong-virtual-machine: ~/SLAM/Chap2/L2_code/Geometry_Exercise/build
File Edit View Search Terminal Help
jindong@jindong-virtual-machine:~/SLAM/Chap2/L2_code/Geometry_Exercise/build$ ./geometry_exercise
use quaternion:
vB = 1.09143 -0.157143 1.57429
vL = -0.641551 0.137248 1.10744
vR = 1.14438 -0.135064 2.07429
vW = 2.37806 -0.134779 0.873485

use Isometry:
vB = 1.09143 -0.157143 1.57429
vL = -0.641551 0.137248 1.10744
vR = 1.14438 -0.135064 2.07429
vW = 2.37806 -0.134779 0.873485
jindong@jindong-virtual-machine:~/SLAM/Chap2/L2_code/Geometry_Exercise/build$
```

5. 旋转的表达

6. 罗德里格斯公式的证明

6.1 证明 $R = \cos \theta \cdot I + (1 - \cos \theta)nn^T + \sin \theta \cdot n^\wedge$

证: 我们让向量 v 绕着方向 n 旋转角度 θ , 得到旋转后的向量 v_{rot} (见下图)

我们可以先通过点积计算 v 在 n 方向上的平行分量 $v_{||}$

$$v_{||} = (v \cdot n)n \quad (1)$$

再通过叉乘得到与 n 正交的两个向量 n_\perp 和 w

$$w = n \times v \quad (2)$$

$$n_\perp = v - v_{||} \quad (3)$$

从图中我们可以得到 v_{rot}


$$v_{rot} = v_{||} + \cos \theta \cdot n_\perp + \sin \theta \cdot w \quad (4)$$

将(1)(2)(3)带入(4), 得到

$$\begin{aligned} v_{rot} &= v_{||} + \cos \theta \cdot (v - v_{||}) + \sin \theta \cdot n \times v \\ &= \cos \theta \cdot v + (1 - \cos \theta) \cdot v_{||} + \sin \theta \cdot n \times v \\ &= \cos \theta \cdot v + (1 - \cos \theta) \cdot \frac{(v \cdot n)n}{\underbrace{=n(v \cdot n)=n(n^T v)=nn^T v}} + \sin \theta \cdot n \times v \\ &= (\cos \theta \cdot I + (1 - \cos \theta)nn^T + \sin \theta \cdot n^\wedge)v \end{aligned}$$

所以将 v 绕着方向 n 旋转角度 θ 到 v_{rot} 的旋转矩阵 R 为

$$R = \cos \theta \cdot I + (1 - \cos \theta)nn^T + \sin \theta \cdot n^\wedge$$



7. 四元数运算性质的验证

(第 5 题和第 7 题为计算题, 故以手写作答)

8. *熟悉 C++11

1) 语句 `std::sort(avec.begin(), avec.end(), [](const A&a1, const A&a2) {return a1.index < a2.index;});`

使用了 lambda 表达式

```
[](const A&a1, const A&a2) {return a1.index<a2.index;}
```

---这里 sort 函数用于遍历容器 avec, 并对容器的成员变量使用匿名 lambda 函数, 每次调用 lambda 函数时都会传入容器 avec 内遍历到的成员变量的引用。由于判断条件为 `a1.index<a2.index`, 故将 avec 内的成员变量以 A.index 的成员参数由小到大进行排列。

2) 语句 `for (auto& a: avec) cout <<a.index << " ";`

---这里使用了序列 for 循环, 用于遍历容器 avec 内的成员变量的引用, 对遍历到的成员变量输出其成员参数 index。

---还使用了自动类型推导 auto, 可以从容器 avec 推断出容器的成员变量的类型为 A, 相当于 `for (A& a: avec) cout <<a.index << " ";`

参考文献:

[1] Rodrigues' rotation formula

https://en.wikipedia.org/wiki/Rodrigues%27_rotation_formula

[2] 30 分钟了解 C++11 新特性